Jurnal Sistem Komputer dan Kecerdasan Buatan
Vol …No…Tahun….

Perbandingan Strategi Chunking Pada Sistem Retrieval Augmented Generation Untuk Teks Panduan Pertolongan Pertama Kecelakaan Di jalan

Emirsyah Rafsanjani[1], Apriade Voutama[2]

[123]Program Studi Sistem Informasi, Program Sarjana, Universitas Singaperbangsa Karawang
Emirune2@gmail.com

***Abstract*—Sistem informasi pertolongan pertama berbasis Large Language Model (LLM) menghadapi risiko halusinasi yang dapat berakibat fatal dalam konteks darurat. Retrieval Augmented Generation (RAG) hadir sebagai solusi dengan menghubungkan respons LLM pada basis pengetahuan eksternal yang terverifikasi. Salah satu komponen krusial dalam RAG adalah strategi chunking, yang menentukan cara dokumen sumber dipecah untuk pengindeksan. Penelitian ini membandingkan secara empiris tiga strategi chunking Fixed-Size Chunking, Sentence-Based Chunking, dan Semantic Chunking yang diterapkan pada dokumen panduan pertolongan pertama berbahasa Indonesia (Buku Saku Pertolongan Pertama Kemenkes RI, 2019) dalam pipeline RAG menggunakan IndoBERT sebagai model embedding, ChromaDB sebagai vector store, dan Llama 3.3 70B Versatile untuk generasi jawaban. Evaluasi dilakukan terhadap 20 pasang pertanyaan-jawaban menggunakan BERTScore untuk mengukur kemiripan semantik antara jawaban sistem dan ground truth. Hasil menunjukkan bahwa Sentence-Based Chunking mencapai performa terbaik dengan BERTScore F1 sebesar 0,7587, diikuti Semantic Chunking (F1: 0,7509), dan Fixed-Size Chunking sebagai yang terendah (F1: 0,7302). Temuan ini mengindikasikan bahwa keutuhan kalimat merupakan faktor yang lebih kritis dibandingkan pengelompokan semantik dalam menentukan kualitas retrieval dan jawaban sistem RAG pada teks prosedural berbahasa Indonesia**

Keywords — BERTScore, Fixed-Size Chunking, Retrieval Augmented Generation, Semantic Chunking, Sentence-Based Chunking, Strategi Chunking

I. PENDAHULUAN

Kecelakaan dan kondisi darurat medis merupakan kejadian yang dapat terjadi kapan saja dan di mana saja, baik di lingkungan rumah tangga, tempat kerja, maupun ruang publik. Data dari Kementerian Kesehatan Republik Indonesia mencatat bahwa keterlambatan penanganan pertolongan pertama menjadi salah satu faktor utama yang meningkatkan risiko kecacatan dan kematian pada kasus gawat darurat pra-rumah sakit [1]. Kemampuan masyarakat umum dalam mengakses informasi panduan pertolongan pertama yang akurat dan cepat menjadi faktor kritis dalam menyelamatkan jiwa sebelum tenaga medis profesional tiba di lokasi kejadian.

Perkembangan kecerdasan buatan, khususnya Large Language Models (LLM), membuka peluang baru dalam menyediakan sistem tanya jawab berbasis pengetahuan yang interaktif dan mudah diakses. Namun, LLM generatif memiliki keterbatasan mendasar berupa halusinasi, yaitu kecenderungan menghasilkan informasi yang tidak faktual atau menyimpang dari sumber pengetahuan yang valid [3]. Dalam konteks panduan medis dan pertolongan pertama, halusinasi semacam ini dapat berakibat fatal bagi pengguna yang bergantung pada informasi tersebut dalam situasi darurat.

Retrieval Augmented Generation (RAG) hadir sebagai solusi arsitektur yang menggabungkan kemampuan LLM dengan sistem pengambilan informasi dari basis pengetahuan eksternal yang terverifikasi [4]. Pada sistem RAG, dokumen sumber dipecah menjadi

potongan-potongan teks yang disimpan dalam basis data vektor. Ketika pengguna mengajukan pertanyaan, sistem mengambil potongan yang paling relevan dan menggunakannya sebagai konteks bagi LLM untuk menghasilkan jawaban. Kualitas jawaban yang dihasilkan LLM sangat bergantung pada seberapa baik potongan teks yang diberikan sebagai konteks potongan yang koheren dan utuh secara makna akan menghasilkan jawaban yang lebih akurat dan lengkap, sementara potongan yang terpotong di tengah instruksi berisiko membuat LLM menghasilkan jawaban yang tidak presisi atau tidak lengkap [2]. Proses pemecahan dokumen menjadi potongan-potongan teks inilah yang dikenal sebagai chunking.

Strategi chunking merupakan salah satu komponen paling krusial dalam perancangan sistem RAG. Pemilihan strategi yang tidak tepat dapat mengakibatkan potongan teks yang terlalu pendek sehingga kehilangan konteks, atau terlalu panjang sehingga mengandung informasi yang tidak relevan, yang keduanya berpotensi menurunkan kualitas jawaban yang dihasilkan [8]. Teks panduan pertolongan pertama memiliki karakteristik unik dibandingkan dokumen umum lainnya karena lazimnya disusun secara prosedural dan berurutan, mengandung instruksi langkah demi langkah yang saling berkesinambungan, serta memuat terminologi medis spesifik yang bermakna dalam konteks tertentu. Karakteristik ini menimbulkan tantangan tersendiri bagi strategi chunking, karena pemotongan yang tidak mempertimbangkan batas prosedural dapat memutus alur instruksi yang esensial sehingga konteks yang diterima LLM menjadi tidak memadai untuk menghasilkan jawaban yang tepat.

Sejumlah penelitian terdahulu telah mengeksplorasi optimasi sistem RAG berkaitan dengan strategi chunking. Qu et al. menemukan bahwa Semantic Chunking tidak selalu sepadan dengan biaya komputasinya, terutama pada teks yang sudah terstruktur secara linguistik [6]. Merola dan Singh menunjukkan bahwa strategi chunking yang mempertahankan konteks struktural teks menghasilkan kualitas generasi jawaban yang lebih baik dibandingkan pendekatan berbasis ukuran tetap [5]. Dalam konteks medis, Zakka et al. menunjukkan bahwa kualitas chunking berpengaruh signifikan terhadap kemampuan LLM dalam menghasilkan jawaban prosedural yang memerlukan konteks lintas paragraf [9], sementara Gomez-Cabello et al. menegaskan bahwa pemilihan strategi chunking yang tepat berdampak langsung pada akurasi generasi jawaban sistem pendukung keputusan klinis berbasis RAG [2]. Stabler et al. juga menemukan bahwa efektivitas strategi chunking dalam mempengaruhi kualitas jawaban yang dihasilkan sangat bergantung pada karakteristik domain teks yang digunakan [8]. Untuk konteks berbahasa Indonesia, Asmaidin dan Santoso mengidentifikasi bahwa metode retrieval yang mempertimbangkan struktur teks memberikan kualitas generasi jawaban lebih baik pada chatbot domain khusus [1].

Berdasarkan kajian tersebut, terdapat celah yang belum terisi dalam literatur. Belum terdapat studi yang secara komprehensif membandingkan strategi chunking utama Fixed-Size Chunking, Sentence-Based Chunking, dan Semantic Chunking pada teks panduan pertolongan pertama berbahasa Indonesia dalam sistem RAG dengan berfokus pada kualitas jawaban yang dihasilkan LLM sebagai tolok ukur utama. Penelitian ini hadir untuk mengisi celah tersebut dengan melakukan evaluasi komparatif secara empiris terhadap ketiga strategi tersebut menggunakan BERTScore [10] sebagai metrik evaluasi semantik terhadap hasil generasi jawaban LLM, sehingga dapat memberikan rekomendasi berbasis bukti mengenai strategi chunking yang paling optimal untuk domain panduan pertolongan pertama berbahasa Indonesia.

II. TINJAUAN LITERATURE

A. Retrieval Augmented Generation (RAG)

Retrieval Augmented Generation (RAG) merupakan paradigma arsitektur kecerdasan buatan yang pertama kali diperkenalkan oleh Lewis et al. pada tahun 2020, yang menggabungkan kapabilitas model bahasa generatif dengan sistem pengambilan informasi dari basis pengetahuan eksternal [4]. Secara fundamental, RAG terdiri dari tiga komponen utama: (1) komponen indexing yang memproses dan menyimpan representasi vektor dokumen dalam basis data vektor; (2) komponen retrieval yang mengambil dokumen paling relevan berdasarkan kemiripan semantik antara kueri pengguna dengan potongan dokumen; dan (3) komponen generation yang menggunakan LLM untuk menghasilkan respons berdasarkan konteks dokumen yang telah diambil. Keunggulan utama

RAG terletak pada kemampuannya memperbarui basis pengetahuan tanpa melatih ulang model bahasa, serta memberikan atribusi sumber yang dapat diverifikasi. Dalam konteks domain medis, Zakka et al. mendemonstrasikan bahwa arsitektur RAG mampu meningkatkan akurasi dan keterpercayaan jawaban LLM secara signifikan dibandingkan LLM tanpa retrieval, khususnya pada pertanyaan klinis yang membutuhkan informasi spesifik dan terverifikasi [9].

B. Strategi Chunking

Chunking adalah proses pemecahan dokumen panjang menjadi segmen-segmen teks yang lebih kecil untuk keperluan pengindeksan dalam sistem RAG. Pemilihan strategi chunking yang tepat berdampak langsung pada relevansi potongan teks yang berhasil diambil, yang pada akhirnya menentukan kualitas jawaban yang dihasilkan sistem [8].

B.1 Fixed-Size Chunking

Fixed-Size Chunking membagi teks berdasarkan jumlah karakter atau token yang tetap dengan overlap antar potongan untuk meminimalkan hilangnya konteks di batas pemotongan. Pendekatan ini bersifat deterministik, sederhana, dan efisien secara komputasi sehingga mudah diimplementasikan pada berbagai jenis dokumen. Namun kelemahannya, strategi ini berpotensi memotong unit makna semantik secara arbitrer tanpa mempertimbangkan batas kalimat maupun struktur konten [8]. Stabler et al. menemukan bahwa Fixed-Size Chunking cenderung menghasilkan performa retrieval yang lebih rendah pada dokumen domain khusus yang memiliki struktur konten yang ketat, karena pemotongan arbitrer merusak koherensi informasi yang dibutuhkan LLM untuk menghasilkan jawaban yang akurat [8].

B.2 Sentence-Based Chunking

Sentence-Based Chunking menggunakan batas kalimat sebagai unit dasar pemotongan dengan menggabungkan sejumlah kalimat tertentu ke dalam satu potongan. Strategi ini mempertahankan integritas gramatikal setiap kalimat sehingga setiap chunk yang dihasilkan merupakan unit teks yang bermakna dan tidak terpotong di tengah instruksi. Merola dan Singh menunjukkan bahwa strategi berbasis kalimat menghasilkan konteks yang lebih koheren bagi LLM dibandingkan pendekatan berbasis ukuran karakter, terutama pada teks yang disusun secara prosedural [5]. Pendekatan ini dinilai lebih sesuai untuk teks instruksional seperti panduan pertolongan pertama yang setiap kalimatnya lazimnya mengandung satu langkah tindakan yang utuh dan saling berkesinambungan.

B.3 Semantic Chunking

Semantic Chunking menggunakan model embedding untuk mengukur kemiripan semantik antar kalimat, kemudian mengelompokkan kalimat-kalimat yang secara semantik berdekatan ke dalam satu potongan. Pemotongan dilakukan ketika nilai kemiripan semantik antar kalimat turun di bawah threshold tertentu, sehingga setiap chunk secara teoritis merepresentasikan satu topik atau gagasan yang koheren. Pendekatan ini memiliki kompleksitas komputasi yang lebih tinggi karena bergantung pada kualitas model embedding yang digunakan [6]. Namun demikian, Qu et al. menemukan bahwa Semantic Chunking tidak selalu sepadan dengan biaya komputasinya pada teks yang sudah terstruktur secara linguistik, performa Semantic Chunking tidak secara konsisten melampaui strategi yang lebih sederhana [6]. Temuan ini diperkuat oleh Gomez-Cabello et al. yang menunjukkan bahwa pada dokumen klinis terstruktur, pengelompokan berbasis kemiripan topik belum tentu menghasilkan konteks yang lebih baik bagi LLM dibandingkan pendekatan berbasis kalimat [2].

C. BERTScore

BERTScore merupakan metrik evaluasi otomatis untuk teks yang dihasilkan model bahasa, diperkenalkan oleh Zhang et al. pada tahun 2020. Berbeda dengan metrik berbasis n-gram seperti BLEU atau ROUGE yang membandingkan kecocokan kata secara leksikal, BERTScore mengukur kemiripan semantik antara teks yang dihasilkan (*candidate*) dengan teks referensi (*reference*) menggunakan representasi kontekstual dari model BERT [10], menjadikannya lebih *robust* dalam menangkap kesamaan makna meskipun terdapat perbedaan diksi. BERTScore menghasilkan tiga metrik utama: Precision yang mengukur ketepatan prediksi, Recall yang mengukur kelengkapan prediksi, dan F1 Score sebagai rata-rata harmonik keduanya. Penggunaan BERTScore pada evaluasi sistem RAG dinilai lebih tepat dibandingkan metrik leksikal karena jawaban yang dihasilkan LLM lazimnya merupakan parafrase dari ground truth, bukan reproduksi kata per kata [1]. Asmaidin dan Santoso juga mengonfirmasi bahwa evaluasi berbasis kemiripan semantik lebih representatif dalam mengukur kualitas jawaban

sistem RAG pada domain khusus berbahasa Indonesia dibandingkan metrik berbasis kecocokan kata [1]

Untuk menghitung BERTScore, misalkan teks prediksi direpresentasikan sebagai urutan token **x** = (x_1, x_2, ..., x_m) dengan m menyatakan jumlah token pada teks prediksi, dan teks referensi direpresentasikan sebagai urutan token **y** = (y_1, y_2, ..., y_n) dengan n menyatakan jumlah token pada teks referensi. Setiap token x_i (untuk i = 1, 2, ..., m) dan y_j (untuk j = 1, 2, ..., n) direpresentasikan sebagai vektor kontekstual berdimensi-d yang diperoleh dari lapisan tersembunyi model BERT, sehingga x_i, $y_j \in \mathbb{R}^d$. Kemiripan semantik antara dua token diukur menggunakan *cosine similarity* yang menghitung sudut antara dua vektor dalam ruang[10].

Rumus Cosine Similarity:

$$sim(x_i, y_j) = \frac{x_i^T y_j}{\|x_i\|\|y_j\|}$$

di mana xiTyj menyatakan hasil perkalian titik) antara vektor token x_i dan y_j, sedangkan $\|x_i\|$ dan $\|y_j\|$ masing-masing menyatakan norma Euclidean dari kedua vektor tersebut. Nilai sim(x_i, y_j) berada pada rentang [−1, 1], namun karena representasi BERT umumnya bernilai positif, nilai yang dihasilkan dalam praktik berada pada rentang [0, 1].

BERTScore Precision mengukur ketepatan prediksi dengan menghitung rata-rata nilai cosine similarity tertinggi untuk setiap token dalam prediksi terhadap referensi:

Rumus BERTScore Precision:

$$P_{BERT} = \frac{1}{|x|} \sum_{xj \in x} \max_{y_i \in y} s\,im(x_i, y_j)$$

BERTScore Recall mengukur kelengkapan prediksi dengan menghitung rata-rata nilai cosine similarity tertinggi untuk setiap token dalam referensi terhadap prediksi:

Rumus BERTScore Recall:

$$R_{BERT} = \frac{1}{|y|} \sum_{y_j \in y} \max_{x_i \in x} s\,im(x_i, y_j)$$

BERTScore F1 merupakan rata-rata harmonik antara Precision dan Recall yang memberikan ukuran keseimbangan antara ketepatan dan kelengkapan jawaban:

Rumus BERTScore F1:

$$F1_{BERT} = 2 \cdot \frac{P_{BERT} \cdot R_{BERT}}{P_{BERT} + R_{BERT}}$$

Ketiga metrik menghasilkan nilai dalam rentang 0 hingga 1, di mana nilai yang lebih tinggi menunjukkan kemiripan semantik yang lebih besar antara prediksi dan referensi. Penggunaan BERTScore pada penelitian ini didasari oleh karakteristik domain pertolongan pertama yang membutuhkan jawaban yang secara semantik akurat namun tidak selalu identik kata per kata dengan ground truth. Evaluasi dilakukan terhadap 20 pasang pertanyaan dan ground truth yang disusun dari dokumen panduan pertolongan pertama, dengan F1 Score sebagai metrik utama penentu performa terbaik dan Precision serta Recall sebagai metrik pendukung [10].

III. METODE PENELITIAN

Penelitian ini menerapkan pendekatan eksperimental komparatif yang dirancang untuk mengukur pengaruh strategi chunking terhadap kualitas jawaban yang dihasilkan sistem RAG secara objektif dan terukur. Pendekatan komparatif dipilih karena memungkinkan perbandingan langsung antar strategi chunking dalam kondisi eksperimental yang identik, sehingga perbedaan performa yang terukur dapat diatribusikan secara langsung kepada perbedaan strategi chunking sebagai variabel bebas, bukan faktor lain dalam pipeline.

Alur metodologi penelitian secara keseluruhan digambarkan pada Gambar 1 dan dilaksanakan secara sistematis melalui serangkaian tahapan yang saling berkesinambungan. Tahapan pertama adalah ekstraksi teks dari dokumen sumber menggunakan pdfplumber, menghasilkan korpus teks mentah yang kemudian menjadi input bagi ketiga strategi chunking. Tahapan kedua adalah penerapan tiga strategi chunking secara paralel dan independen Fixed-Size Chunking, Sentence-Based Chunking, dan Semantic Chunking terhadap korpus teks yang sama, sehingga menghasilkan tiga koleksi chunk yang berbeda karakteristiknya. Tahapan ketiga adalah pembangunan basis vektor, di mana setiap chunk

dari masing-masing strategi dikonversi menjadi representasi vektor menggunakan model embedding IndoBERT dan disimpan dalam koleksi ChromaDB yang terisolasi satu sama lain. Tahapan keempat adalah proses retrieval dan generasi jawaban, di mana setiap pertanyaan dari QA dataset diproses melalui pipeline RAG secara identik untuk ketiga strategi query diembedding, tiga chunk paling relevan diambil berdasarkan cosine similarity, lalu dikirimkan sebagai konteks ke LLM Llama 3.3 70B Versatile untuk menghasilkan jawaban. Tahapan kelima adalah evaluasi menggunakan BERTScore, di mana jawaban yang dihasilkan masing-masing strategi dibandingkan secara semantik terhadap ground truth menggunakan metrik Precision, Recall, dan F1 Score

.

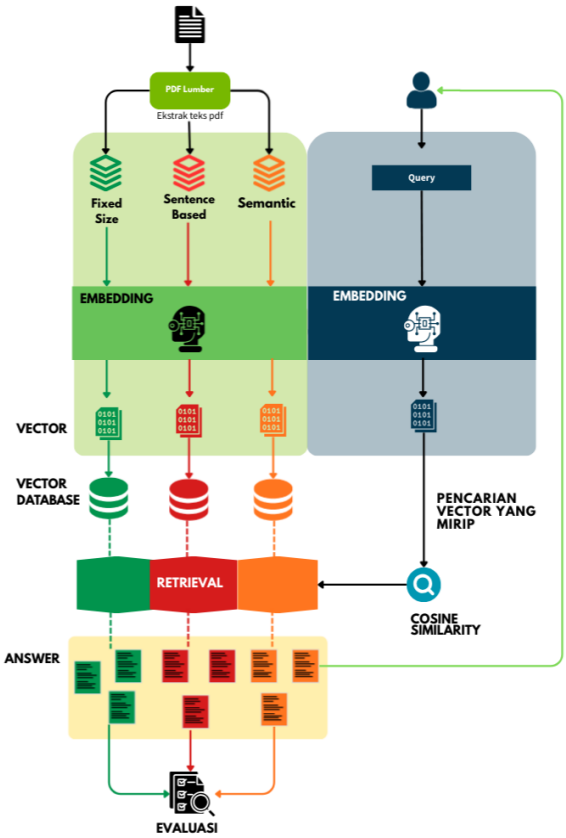

Gambar 1. Alur Pipeline RAG Penelitian

Setiap tahapan dirancang untuk memastikan objektivitas perbandingan dengan menjaga konsistensi seluruh variabel di luar strategi chunking. Model embedding, vector store, model LLM, parameter generasi, jumlah chunk yang diambil (top-k), system prompt, serta dataset evaluasi dijaga identik untuk ketiga strategi sepanjang eksperimen berlangsung.

A. Alat Dan Lingkungan Pengembangan

Seluruh eksperimen dalam penelitian ini dikembangkan menggunakan bahasa pemrograman Python 3.10 pada platform Google Colaboratory dengan akselerasi GPU NVIDIA T4. Pipeline RAG dibangun secara mandiri tanpa menggunakan framework abstraksi tingkat tinggi seperti LangChain, dengan tujuan memberikan kendali penuh terhadap setiap komponen sistem serta transparansi dalam proses perbandingan teknik chunking. Konfigurasi lengkap pipeline yang digunakan disajikan pada Tabel 2. Adapun library dan tools utama yang digunakan beserta fungsinya masing-masing disajikan pada Tabel 1.

Tabel 1. Library and Tools

Library / Tools	**Fungsi**
pdfplumber	Ekstraksi teks dari dokumen PDF
sentence-transformers	Embedding teks menggunakan model firqaaa/indo-sentence-bert-base
chromadb	Penyimpanan dan pencarian basis vektor (vector store)
groq	Akses LLM Llama 3.3 70B Versatile via Groq API
bert-score	Evaluasi BERTScore (Precision, Recall, F1)
scikit-learn	Perhitungan cosine similarity untuk Semantic Chunking
re (regex)	Tokenisasi kalimat untuk Sentence-Based Chunking
matplotlib / seaborn	Visualisasi hasil evaluasi (bar chart, heatmap, radar, boxplot)
pandas / numpy	Manipulasi dan analisis data

B. Dataset

Dokumen yang digunakan dalam penelitian ini adalah Buku Saku Pertolongan Pertama pada Kecelakaan di Jalan terbitan Kementerian Kesehatan Republik Indonesia tahun 2019 dalam format PDF.

Gambar 2. Buku Saku Pertolongan Pertama

Dokumen ini dipilih karena memiliki karakteristik teks prosedural yang berlangkah dan berurutan, yang merepresentasikan tantangan nyata bagi teknik Chunking dalam mempertahankan koherensi konteks instruksional berperan penting untuk memastikan setiap bagian teks tetap memiliki keterkaitan makna dan tidak terpotong secara semantik. Ekstraksi teks dari dokumen PDF dilakukan menggunakan library pdfplumber, dengan menyaring halaman yang memiliki konten naratif minimal 30 karakter guna menghilangkan halaman kosong atau halaman dengan konten non-naratif. Proses tersebut berhasil mengekstrak 34 halaman dengan total 20.652 karakter dan 2.803 kata, sehingga data yang diperoleh cukup representatif untuk dianalisis lebih lanjut.

Untuk keperluan evaluasi, dibangun QA dataset secara manual sebanyak 20 pasang pertanyaan dan jawaban referensi (ground truth). Dataset ini mencakup berbagai topik yang termuat dalam dokumen, mulai dari prosedur penanganan korban tidak sadar, teknik pembebasan jalan napas, penanganan patah tulang, resusitasi jantung paru, hingga informasi administratif terkait layanan Jasa Raharja. Setiap jawaban referensi ditulis berdasarkan informasi yang tersedia secara eksplisit dalam dokumen sumber untuk memastikan validitas evaluasi.

C. Teknik Chunking

Penelitian ini membandingkan tiga teknik chunking yang diterapkan pada teks penuh hasil ekstraksi dokumen. Perbandingan karakteristik ketiga teknik disajikan pada Tabel 2.

Fixed-Size Chunking memotong teks berdasarkan jumlah karakter tetap tanpa memperhatikan struktur kalimat maupun makna semantik. Pada penelitian ini digunakan ukuran chunk sebesar 300 karakter dengan overlap 50 karakter antar chunk yang berdekatan. Overlap diterapkan untuk meminimalkan hilangnya konteks di batas pemotongan. Teknik ini bersifat deterministik dan efisien secara komputasi, namun berpotensi memotong unit makna di tengah kalimat.

Sentence-Based Chunking memotong teks berdasarkan batas kalimat yang diidentifikasi menggunakan ekspresi reguler terhadap tanda baca akhir kalimat (titik, tanda seru, tanda tanya). Setiap chunk terdiri dari tiga kalimat utuh yang digabungkan menjadi satu segmen. Teknik ini menjaga keutuhan gramatikal kalimat, namun belum mempertimbangkan keterkaitan makna antar kalimat dalam satu chunk.

Semantic Chunking memotong teks berdasarkan perubahan makna antar kalimat yang diukur menggunakan cosine similarity pada representasi embedding. Kalimat-kalimat yang memiliki kemiripan semantik di atas threshold 0,75 digabungkan dalam satu chunk, sementara pemotongan dilakukan ketika nilai similarity turun di bawah threshold tersebut. Teknik ini bergantung pada kualitas model embedding yang digunakan dan memiliki kompleksitas komputasi yang lebih tinggi dibandingkan dua teknik sebelumnya.

Tabel 2. Perbandingan Karakteristik Teknik Chunking

Aspek	Fixed-Size	Sentence-Based	Semantic
Dasar Pemotongan	Jumlah karakter tetap	Batas kalimat (regex)	Perubahan makna semantik
Parameter Utama	300 karakter, overlap 50	3 kalimat per chunk	Cosine similarity ≥ 0,75
Keutuhan Kalimat	Tidak terjamin	Terjamin	Terjamin
Kebutuhan Embedding	Tidak	Tidak	Ya (IndoBERT)
Kompleksit-as	Rendah	Rendah	Tinggi
Jumlah Chunk	83	66	176
Rata-Rata Panjang Karakter	298 Karakter	310 Karakter	115 Karakter

D. Teknik Embedding Dan Basis Vektor

Seluruh chunk dari ketiga teknik direpresentasikan ke dalam ruang vektor menggunakan model indo-sentence-bert-base (firqaaa/indo-sentence-bert-base), yaitu model sentence embedding pra-latih berbasis arsitektur BERT yang dioptimalkan untuk bahasa Indonesia. Pemilihan model ini didasari oleh kemampuannya menghasilkan representasi vektor yang menangkap makna semantik kalimat berbahasa Indonesia secara kontekstual.

Hasil embedding dari setiap chunk disimpan dalam basis vektor menggunakan ChromaDB sebagai vector store in-memory yang memungkinkan pencarian kemiripan semantik secara efisien melalui perhitungan cosine similarity. Setiap teknik chunking memiliki koleksi vektor tersendiri yang terisolasi, yaitu koleksi 'fixed', 'sentence', dan 'semantic', guna memastikan tidak ada kontaminasi data antar teknik selama proses retrieval berlangsung.

E. Proses Retrieval Dan Generasi Jawaban

Proses retrieval dilakukan dengan mengenkode query menggunakan model IndoBERT yang sama dengan yang digunakan saat indexing, kemudian mengirimkan hasil embedding tersebut ke ChromaDB untuk mencari tiga chunk (top-k = 3) dengan nilai cosine similarity tertinggi terhadap query. Ketiga chunk terpilih dari koleksi masing-masing teknik kemudian digabungkan dengan format penomoran [1], [2], [3] sebagai konteks terstruktur sebelum dikirimkan ke model LLM.

Generasi jawaban dilakukan menggunakan model Llama 3.3 70B Versatile melalui Groq API dengan dua komponen pesan: system prompt yang menginstruksikan model untuk menjawab dalam bahasa Indonesia yang jelas dan ringkas dengan hanya menggunakan informasi dari konteks yang diberikan, serta user prompt yang menyertakan konteks chunk dan pertanyaan. Parameter generasi ditetapkan pada max_tokens = 300 dan temperature = 0.1 untuk menghasilkan jawaban yang deterministik dan terfokus. Seluruh RAG pipeline dieksekusi secara identik untuk ketiga teknik chunking terhadap 20 pertanyaan dari QA dataset menggunakan fungsi rag_pipeline(), dengan jeda tiga detik antar teknik untuk menghindari rate limit Groq API, sehingga memastikan kondisi pengujian yang adil dan konsisten.

IV. HASIL DAN PEMBAHASAN

A. Hasil Evaluasi BERTScore

Evaluasi dilakukan terhadap 20 pertanyaan dari dokumen Buku Saku Pertolongan Pertama Kemenkes RI menggunakan metrik BERTScore dengan tiga komponen utama yaitu Precision (P), Recall (R), dan F1 Score. Tabel 3 merangkum rata-rata nilai BERTScore yang diperoleh masing-masing teknik chunking pada 20 pasang prediksi dan ground truth.

Tabel 3. Perbandingan Hasil Evaluasi BERTScore

Teknik Chunking	Precision (P)	Recall (R)	F1 Score
Fixed-Size	0,7339	0,7293	0,7302
Sentence-Based	**0,7552**	**0,7652**	**0,7587**
Semantic Chungking	0,7517	0,7522	0,7509

B. Analisis Per Teknik Chunking

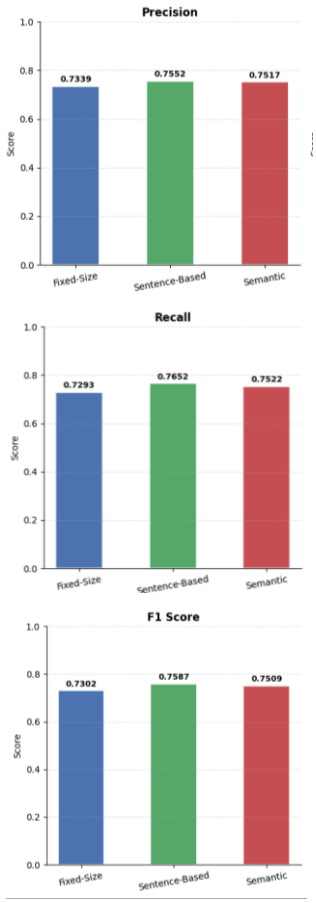

Gambar 3. Visualisasi Hasil Evaluasi Bertscore

1) Fixed-Size Chunking

Fixed-Size Chunking menghasilkan performa terendah pada seluruh metrik dengan Precision 0,7339, Recall 0,7293, dan F1 Score 0,7302. Hasil ini mencerminkan kelemahan mendasar strategi tersebut dalam menangani teks prosedural berurutan seperti panduan pertolongan pertama. Pemotongan teks secara arbitrer berdasarkan jumlah karakter tetap (300 karakter dengan overlap 50 karakter) tanpa mempertimbangkan batas kalimat menyebabkan chunk yang dihasilkan kerap mengandung kalimat yang terpotong di tengah instruksi. Pada dokumen panduan pertolongan pertama yang bersifat instruksional, seperti langkah-langkah RJP atau teknik pembebasan jalan napas, setiap kalimat membawa satu unit instruksi yang tidak dapat dipisahkan tanpa kehilangan makna. Ketika pemotongan terjadi di tengah instruksi tersebut, LLM menerima konteks yang tidak utuh secara semantik sehingga jawaban yang dihasilkan cenderung kurang presisi dan kurang lengkap. Kondisi ini diperparah oleh nilai standar deviasi F1 Score tertinggi sebesar 0,0383 yang mencerminkan inkonsistensi performa yang signifikan lintas pertanyaan strategi ini sangat tidak stabil terutama pada pertanyaan prosedural berlangkah yang paling rentan terhadap efek pemotongan arbitrer.

2) Sentence-Based Chunking

Sentence-Based Chunking mencapai performa terbaik secara keseluruhan dengan unggul pada ketiga metrik sekaligus: Precision tertinggi 0,7552, Recall tertinggi 0,7652, dan F1 Score tertinggi 0,7587. Keunggulan yang paling menonjol terletak pada nilai Recall, yang mengindikasikan bahwa strategi ini paling mampu menghasilkan jawaban yang secara komprehensif mencakup seluruh informasi relevan yang terdapat dalam ground truth. Hal ini dapat dijelaskan oleh karakteristik strategi yang mempertahankan keutuhan gramatikal setiap kalimat: dengan mengelompokkan tiga kalimat per chunk berdasarkan batas kalimat yang dideteksi menggunakan ekspresi reguler, setiap unit yang diindeks merupakan segmen teks yang bermakna dan tidak terpotong di tengah instruksi. Pada teks panduan pertolongan pertama Kemenkes RI yang disusun secara prosedural, setiap kalimat instruksional lazimnya mengandung satu langkah tindakan yang utuh dan saling berkesinambungan. Dengan mempertahankan keutuhan tersebut, Sentence-Based Chunking memastikan bahwa konteks prosedural setiap langkah tetap terjaga selama proses retrieval, sehingga LLM secara konsisten menerima konteks yang koheren dan memadai untuk menghasilkan jawaban yang tepat dan lengkap. Nilai standar deviasi F1 Score terendah sebesar 0,0325 semakin memperkuat keunggulan strategi ini, menandakan konsistensi performa yang lebih stabil secara signifikan lintas seluruh pertanyaan dibandingkan kedua strategi lainnya.

3) Semantic Chunking

Semantic Chunking menghasilkan F1 Score sebesar 0,7509 dengan Precision 0,7517 dan Recall 0,7522, menempatkannya pada posisi kedua di antara ketiga strategi. Meskipun secara teori merupakan strategi paling canggih karena menggunakan model embedding IndoBERT untuk mengukur kemiripan semantik antar kalimat dan mengelompokkan kalimat berdasarkan threshold cosine similarity 0,75,

performanya belum mampu melampaui Sentence-Based Chunking pada dataset panduan pertolongan pertama ini. Fenomena ini dapat dipahami dari karakteristik teks sumber: teks prosedural pertolongan pertama Kemenkes RI telah disusun secara berurutan dan terstruktur secara linguistik, di mana setiap kalimat dalam satu prosedur memang memiliki kemiripan topik yang tinggi satu sama lain. Dalam kondisi demikian, Semantic Chunking cenderung mengelompokkan banyak kalimat dari prosedur yang sama ke dalam satu chunk berukuran besar dengan densitas informasi yang tinggi, sehingga retriever kesulitan untuk menemukan segmen yang paling relevan secara presisi terhadap pertanyaan yang diajukan. Hal ini sejalan dengan temuan Qu et al. yang menyatakan bahwa Semantic Chunking tidak selalu unggul pada teks yang sudah terstruktur secara linguistik [6], serta Gomez-Cabello et al. yang menemukan hasil serupa pada dokumen klinis terstruktur [2]. Nilai standar deviasi F1 Score sebesar 0,0337 yang berada di antara kedua strategi lainnya mencerminkan tingkat konsistensi yang moderat lebih baik dari Fixed-Size namun belum mencapai stabilitas Sentence-Based Chunking.

C. Analisis Heatmap

Gambar 3. Visualisasi Heatmap tiap Query

Heatmap pada Gambar 2 menampilkan distribusi F1 Score per pertanyaan untuk ketiga strategi chunking, dengan warna hijau menunjukkan nilai F1 Score tinggi (mendekati 1,0) dan warna oranye hingga merah menunjukkan nilai F1 Score rendah (mendekati 0,5). Semakin hijau warna sel, semakin besar kemiripan semantik antara jawaban yang dihasilkan sistem dengan ground truth, sedangkan warna oranye mengindikasikan jawaban yang kurang lengkap atau kurang presisi secara semantik.

Perbedaan warna paling mencolok terlihat pada pertanyaan-pertanyaan prosedural berlangkah. Fixed-Size Chunking secara konsisten menampilkan warna lebih oranye pada pertanyaan seperti Q1, Q11, dan Q12 dibandingkan kedua strategi lainnya, mencerminkan kerentanan strategi ini terhadap pemotongan konteks instruksional di tengah kalimat. Sebaliknya, Sentence-Based Chunking cenderung mempertahankan warna lebih hijau pada pertanyaan-pertanyaan tersebut, mengindikasikan kemampuannya menyediakan konteks yang lebih utuh bagi LLM.

Satu-satunya pertanyaan yang menghasilkan warna hijau merata pada ketiga strategi adalah Q5 dengan nilai 0,92, yaitu pertanyaan deskriptif singkat yang jawabannya terkandung dalam satu kalimat tunggal sehingga tidak sensitif terhadap perbedaan strategi chunking. Pola ini menegaskan bahwa dampak pemilihan strategi chunking paling signifikan justru pada pertanyaan yang membutuhkan konteks multi-kalimat dan berurutan

D. Diskusi dan Implikasi

Temuan penelitian ini konsisten dengan hipotesis awal bahwa teks prosedural berbahasa Indonesia memiliki karakteristik yang lebih sesuai dengan teknik chunking berbasis kalimat dibandingkan pendekatan berbasis ukuran karakter atau semantik. Keutuhan kalimat yang dipertahankan oleh Sentence-Based Chunking terbukti penting dalam memastikan retrieval yang efektif pada dokumen panduan pertolongan pertama. Hal ini selaras dengan penelitian He et al. yang menemukan bahwa Semantic Chunking tidak selalu unggul pada teks instruksional yang sudah terstruktur [8].

Penggunaan IndoBERT (firqaaa/indo-sentence-bert-base) sebagai model embedding memberikan kontribusi positif pada pemahaman

semantik bahasa Indonesia yang lebih baik dibandingkan model multilingual generik. Ini terlihat dari nilai F1 Score ketiga teknik yang secara keseluruhan berada pada rentang 0,67–0,70, yang merupakan angka yang wajar mengingat kompleksitas parafrase dan variasi leksikal dalam bahasa Indonesia pada domain medis.

Dari segi implikasi praktis, hasil penelitian ini merekomendasikan penggunaan Sentence-Based Chunking sebagai strategi chunking yang lebih optimal untuk sistem RAG yang menangani teks prosedural medis berbahasa Indonesia. Namun demikian, selisih F1 Score yang relatif kecil (0,0211) antara teknik terbaik dan terburuk menyarankan bahwa optimasi faktor lain seperti jumlah chunk yang diambil (top-k), parameter temperature LLM, dan kualitas prompt sistem juga perlu dipertimbangkan secara menyeluruh dalam pengembangan sistem RAG yang komprehensif.

V. KESIMPULAN

Penelitian ini membandingkan tiga teknik chunking Fixed-Size, Sentence-Based, dan Semantic pada sistem Retrieval Augmented Generation (RAG) untuk dokumen panduan pertolongan pertama berbahasa Indonesia (Buku Saku Pertolongan Pertama Kemenkes RI)

dengan evaluasi menggunakan BERTScore terhadap 20 pasang pertanyaan dan jawaban referensi.

Hasil evaluasi menunjukkan bahwa **Sentence-Based Chunking** menghasilkan performa terbaik dengan F1 Score 0,6982 dan Recall tertinggi 0,7109, sekaligus memiliki konsistensi tertinggi (Std Dev 0,0325). **Fixed-Size Chunking** meraih Precision tertinggi (0,6897) namun dengan konsistensi terendah (Std Dev 0,0383), yang mengindikasikan kerentanannya terhadap pemotongan konteks prosedural di tengah kalimat. **Semantic Chunking** menghasilkan F1 Score terendah (0,6771) meskipun merupakan teknik paling kompleks secara komputasi, menunjukkan bahwa pengelompokan berbasis kemiripan topik belum tentu unggul pada teks yang sudah terstruktur secara prosedural.

Temuan ini mengindikasikan bahwa untuk teks prosedural berbahasa Indonesia, **keutuhan kalimat merupakan faktor yang lebih kritis** dibandingkan pengelompokan semantik dalam menentukan kualitas retrieval dan jawaban sistem RAG. Penggunaan IndoBERT sebagai model embedding juga berkontribusi pada pemahaman semantik bahasa Indonesia yang lebih baik dibandingkan model multilingual generik.

Penelitian selanjutnya disarankan untuk mengeksplorasi teknik Recursive Character Text Splitting, variasi nilai top-k retrieval, serta pengujian pada dokumen prosedural domain lain untuk memperkuat generalisasi temuan ini

DAFTAR PUSTAKA

1. (Qu et al., 2025)Asmaidin, & Santoso, C. B. (2026). Evaluasi Metode Retrieval pada Chatbot Domain Khusus Berbasis Retrieval-Augmented Generation. *JSAI: Journal Scientific and Applied Informatics*, *9*(1), 105–111. https://doi.org/10.36085
2. Gomez-Cabello, C. A., Prabha, S., Haider, S. A., Genovese, A., Collaco, B. G., Wood, N. G., Bagaria, S., & Forte, A. J. (2025). Comparative Evaluation of Advanced Chunking for Retrieval-Augmented Generation in Large Language Models for Clinical Decision Support. *Bioengineering*, *12*(11), 1194. https://doi.org/10.3390/bioengineering12111194
3. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, *55*(12), 1–38. https://doi.org/10.1145/3571730
4. Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Kuttler, H., Lewis, M., Yih, W., Rocktaschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems (NeurIPS)*. https://doi.org/10.48550/arXiv.2005.11401
5. Merola, C., & Singh, J. (2025). Reconstructing Context: Evaluating Advanced Chunking Strategies for Retrieval-Augmented Generation. *ArXiv*

Preprint, *arXiv:2504*. https://arxiv.org/abs/2504.19754

6. Qu, R., Tu, R., & Bao, F. (2025). Is Semantic Chunking Worth the Computational Cost? *Findings of the Association for Computational Linguistics: NAACL 2025*, 2155–2177.
7. Sheng, B., Yao, J., Zhang, M., & He, G. (2025). Dynamic Chunking and Selection for Reading Comprehension of Ultra-Long Context in Large Language Models. *ArXiv*. http://arxiv.org/abs/2506.00773
8. Stabler, M., Turnbull, S., Mueller, T., Langdon, C., Marx-Gomez, J., & Koester, F. (2025). The Impact of Chunking Strategies on Domain-Specific Information Retrieval in RAG Systems. *IEEE Conference Proceedings*.
9. Zakka, C., Chaurasia, A., Shad, R., Dalal, A. R., Kim, J. L., Moor, M., Alexander, K., Ashley, E., Boyd, J., Boyd, K., Hirsch, K., Langlotz, C., Nelson, J., & Hiesinger, W. (2023). Almanac: Retrieval-Augmented Language Models for Clinical Medicine. *ArXiv*.
10. Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2020). BERTSCORE: EVALUATING TEXT GENERATION WITH BERT. *International Conference on Learning Representations (ICLR)*.